

Estatística Descritiva

Rodrigo R. Pescim

Universidade Estadual de Londrina

Departamento de Estatística - CCE/UEL

- A **ciência estatística** tem por interesse a coleta, a apresentação, a análise e a utilização dos dados para tomar decisões, resolver problemas e planejar processos
- Os **métodos estatísticos** são utilizados para compreender o conceito de variabilidade
- **Variabilidade** → “Sucessivas observações de um fenômeno que não produz exatamente o mesmo resultado”

Exemplo 1

- Algumas estruturas nas áreas de construção e engenharia civil são expostas a “forças naturais”.
- Essas estruturas podem sofrer, ao longo do tempo, **degradação** (deterioração, fadiga, deformação, etc.) e também sofrer do efeito de **fatores externos** (corrosão, sobrecarga ou riscos ambientais).
- Assim, **as respostas associadas a esses fatores** nas estruturas não devem ser consideradas constante, mas sim, como **uma variação de um fenômeno aleatório**.


Exemplo 2

- Um artigo do periódico *Quality Engineering* apresenta dados de viscosidade (Pa.s) de um processo químico em batelada. Uma amostra desses dados é apresentada a seguir.

1,570	1,720	1,900	2,400	2,522	2,700
2,720	2,750	2,800	3,125	3,200	3,250
3,400	3,450	3,600	3,720	4,100	4,600

- Como retirar as primeiras informações sobre a viscosidade de um fluido num processo químico ?

- Tem por objetivo resumir e apresentar os dados sob a forma de **tabelas e gráficos**, além de estudar os parâmetros e suas estimativas.
- **Organização:** Como “tratar” os dados a fim de extrair informações a respeito de uma ou mais características de interesse ?
- **Variáveis:** Uma variável, neste contexto, é uma medida numérica ou classificação obtida a partir de uma característica de interesse de uma população em estudo.
- Exemplo:
 - Variável $X \rightarrow$ refere-se a viscosidade de um processo químico
 - $x_i, i = 1, \dots, 18$ é o valor observado da viscosidade em cada unidade experimental
 - $x_1 = 1,570; x_2 = 1,720; x_3 = 1,900; \dots$



Tipos de Variáveis

- Os tipos de variáveis mais comumente utilizadas na descrição dos dados são: Quantitativas (Discretas ou Contínuas) e Qualitativas (nominais ou ordinais)
- Exemplos de variáveis quantitativas discretas:
 - Número de peças defeituosas;
 - Número de bits transmitidos que foram recebidos com erros;
 - Número de lâmpadas queimadas
- Exemplos de variáveis quantitativas contínuas:
 - Intensidade de corrente elétrica;
 - Tempo de falha de uma estrutura metálica;
 - Medidas de voltagem, comprimento, pressão, temperatura, etc.

- Exemplos de variáveis qualitativas nominais (ou categóricas):
 - Sexo;
 - Nacionalidade;
 - Área de atividade
- Exemplos de variáveis qualitativas ordinais:
 - Classes sociais;
 - Nível de instrução;
 - Categoria de clientes (ouro, prata e bronze)

Exercício 1

- Um levantamento foi realizado com 10 funcionários de uma construtora e os resultados obtidos são informados na tabela abaixo.

ID	Est. Civil	Instrução	Filhos	Salário	Idade
1	1	1	0	4,00	26
2	2	1	1	4,56	32
3	2	1	2	5,25	36
4	1	2	0	5,73	20
5	1	1	0	6,26	40
6	2	1	0	6,66	28
7	1	1	0	6,86	41
8	1	1	0	7,39	43
9	2	2	1	7,59	34
10	1	2	0	7,44	23

- Classifique as variáveis em quantitativas (discretas ou contínuas) ou qualitativas (nominais ou ordinais).

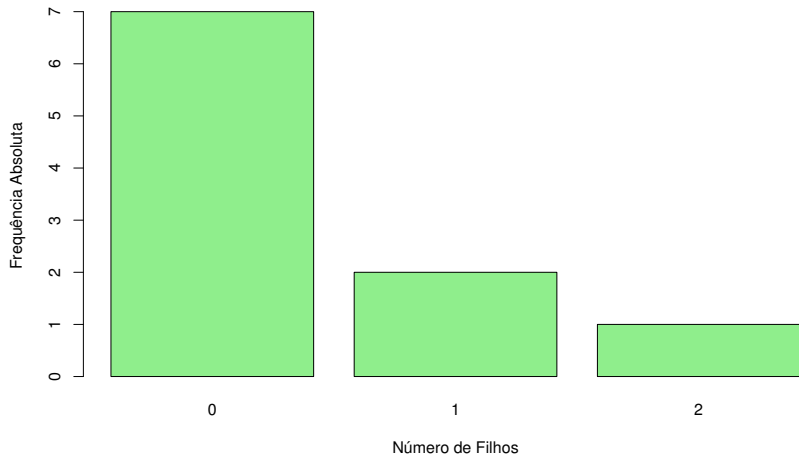
Tabela de Distribuições de Frequências


- Uma **distribuição de frequências** relaciona **categorias ou classes de valores** juntamente com as **frequências do número de valores** que se enquadram em cada categoria ou classe.
- Nas tabelas de distribuição de frequências - é usual fornecer a proporção (frequência relativa) das unidades que são de cada uma das variáveis
- **Para obter a frequência absoluta de uma dada variável**
 - Frequência absoluta (f_i)
 - Frequência absoluta acumulada (F_i)
- **Para obter a frequência relativa de uma dada variável**
 - Frequência relativa (f'_i)
 - Frequência relativa (F'_i)
- Como organizar os dados da variável Filhos em uma tabela de distribuição de frequências ?

Tabela 1: Número de filhos de uma certa empresa

Nº de Filhos	f_i	f'_i	F_i	F'_i
0	7	0,7	7	0,7
1	2	0,2	9	0,9
2	1	0,1	10	1
Total	10	1	-	-

- **Gráfico de Barras:** É mais apropriado para variáveis qualitativas ordinais e para variáveis quantitativas discretas.
 - Ex: Número de filhos (variável quantitativa discreta); Grau de instrução (variável qualitativa ordinal)
- **Gráfico de Setores:** É mais apropriado para variáveis qualitativas nominais, pois tem por objetivo a visualização do quanto a informação de cada parte está representada no todo.
 - Ex: Estado civil (variável qualitativa nominal)





Distribuições de Frequências e sua representação Gráfica para Variáveis Quantitativas Contínuas

- As variáveis quantitativas contínuas diferem um pouco das discretas na sua forma de representação gráfica
- Observa-se que essas variáveis, por definição, têm seus valores definidos no conjunto dos números reais
- Assim, não tem sentido falar em frequência de repetição de um determinado valor, pois os valores raramente se repetem (exemplo 2)

Método da raiz quadrada

1. Determinar o número de classes (ou intervalos) (k)

$$k = \sqrt{n}$$

2. Determinar a amplitude de cada intervalo (c)

$$c = \frac{A}{k - 1},$$

em que $A = x_{\max} - x_{\min}$

3. Determinar a 1ª classe (ou intervalo) : $[LI; LS)$ ou $LI \vdash LS$

$$LI = x_{\min} - \frac{c}{2} \quad \text{e} \quad LS = x_{\min} + \frac{c}{2}$$

Classe	Notação	Denominação	Resultado
$[a, b)$	$a \vdash b$	Fechado em a , aberto em b	Inclui a , não inclui b
$(a, b]$	$a \dashv b$	Aberto em a , fechado em b	Não inclui a , inclui b

Dados de viscosidade: Método da raiz quadrada

Observa-se que $n = 18$, então

Dados de viscosidade: Método da raiz quadrada

Observa-se que $n = 18$, então

$$k = \sqrt{n} = \sqrt{18} \approx 4,242 = 4.$$

Dados de viscosidade: Método da raiz quadrada

Observa-se que $n = 18$, então

$$k = \sqrt{n} = \sqrt{18} \approx 4,242 = 4.$$

Assim, temos $k = 4$ **intervalos (ou classes) de frequências**.

Dados de viscosidade: Método da raiz quadrada

Observa-se que $n = 18$, então

$$k = \sqrt{n} = \sqrt{18} \approx 4,242 = 4.$$

Assim, temos $k = 4$ **intervalos (ou classes) de frequências**.

Como $A = x_{\text{máx}} - x_{\text{min}}$ então

Dados de viscosidade: Método da raiz quadrada

Observa-se que $n = 18$, então

$$k = \sqrt{n} = \sqrt{18} \approx 4,242 = 4.$$

Assim, temos $k = 4$ **intervalos (ou classes) de frequências**.

Como $A = x_{\text{máx}} - x_{\text{min}}$ então

$$c = \frac{A}{k - 1} = \frac{4,6 - 1,570}{3} = 1,01$$

Portanto, a **amplitude de cada intervalo é** $c = 1,01$.

Dados de viscosidade: Método da raiz quadrada

Para determinar a 1ª classe (ou intervalo) : $[LI; LS)$, temos

$$LI = x_{min} - \frac{c}{2} \quad \text{e} \quad LS = x_{min} + \frac{c}{2}$$

Então,

$$LI = 1,570 - \frac{1,01}{2} = 1,065 \quad \text{e} \quad LS = 1,570 + \frac{c}{2} = 2,075$$

Portanto, 1ª classe (ou intervalo) é representado por


$$[1,065; 2,075) \quad \text{ou} \quad 1,065 \vdash 2,075$$

Dados de viscosidade: Tabela de frequências para variável quantitativa contínua

Viscosidade	f_i	f'_i	F_i	F'_i
1,065 ┤ 2,075	3	0,167	3	0,167
2,075 ┤ 3,085	6	0,333	9	0,5
3,085 ┤ 4,095	7	0,389	16	0,889
4,095 ┤ 5,105	2	0,111	18	1
Total	18	1	-	-

- Muito utilizado para avaliar o comportamento de variáveis quantitativas, principalmente as contínuas
- Quando os dados estão agrupados em classes - o histograma apresenta as frequências das classes em colunas
- As frequências representadas podem ser simples ou relativas
- As colunas possuem bases com mesma largura
- Não existe espaço entre as classes

Histograma dos Dados



- Às vezes, tem-se o interesse em resumir um conjunto de dados, apresentando um ou alguns valores que representem todo conjunto de dados.
- Para determinar esses valores, utiliza-se as **medidas de posição central**: Média, Mediana e Moda.

Média Amostral

- Sejam X_1, \dots, X_n , n valores amostrais. A média amostral (\bar{X}) é definida por

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n} = \frac{X_1 + \dots + X_n}{n}$$

- Exemplo: Notas das provas dos alunos da UEL: 6,4,5,4,6

$$\bar{X} = \frac{6 + 4 + 5 + 4 + 6}{5} = 5,0.$$

- A média é considerada a **melhor medida de centro**, pois possui boas propriedades matemáticas
- Entretanto, ela é **falha** quando alguns dos valores estão muito **afastados da maioria dos dados**. (Valores extremos, valores aberrantes, outliers, etc).

Exemplo

Imagine o seguinte banco de dados: 6, 4, 5, 4, 50

Qual é o valor da média amostral ?

$$\bar{X} = \frac{6 + 4 + 5 + 4 + 50}{5} = 13,8.$$

Observa-se que a média amostral foi afetada por um valor aproximadamente 10 vezes maior do que a maioria dos dados na amostra. Algumas perguntas podem surgir nesse momento, como:

- O Valor $x = 50$ é um valor extremo (outlier)?
- Como podemos identificar um valor extremo ?
- É razoável pensar, neste caso, que a média não seja a melhor medida para representar a informação central dos dados. Neste sentido, o que podemos fazer para contornar esse problema?

- A Mediana (Md) divide um conjunto ordenado (ordem crescente) de valores em duas partes iguais. É definida por

$$Md = \begin{cases} x_{(\frac{n+1}{2})}, & \text{se } n \text{ for ímpar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}, & \text{se } n \text{ for par} \end{cases}$$

- A Moda (Mo) é definida como a realização mais frequente do conjunto de dados observados.

Exemplo: Notas dos alunos da UEL

Imagine o seguinte banco de dados: 6, 4, 5, 4, 6

Qual é o valor da mediana ?

Exemplo: Notas dos alunos da UEL

Imagine o seguinte banco de dados: 6, 4, 5, 4, 6

Qual é o valor da mediana ?

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{6}}$

Exemplo: Notas dos alunos da UEL

Imagine o seguinte banco de dados: 6, 4, 5, 4, 6

Qual é o valor da mediana ?

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{6}}$

Como $n = 5$, então a mediana é dada por

$$Md = x_{(\frac{n+1}{2})} = x_{(\frac{5+1}{2})} = x_3 = 5,0.$$

Exemplo: Notas dos alunos da UEL

Imagine o seguinte banco de dados: 6, 4, 5, 4, 6

Qual é o valor da mediana ?

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{6}}$

Como $n = 5$, então a mediana é dada por

$$Md = x_{(\frac{n+1}{2})} = x_{(\frac{5+1}{2})} = x_3 = 5,0.$$

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{6}}$

Exemplo: Notas dos alunos da UEL

Imagine o seguinte banco de dados: 6, 4, 5, 4, 6

Qual é o valor da mediana ?

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{6}}$

Como $n = 5$, então a mediana é dada por

$$Md = x_{(\frac{n+1}{2})} = x_{(\frac{5+1}{2})} = x_3 = 5, 0.$$

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{6}}$

Observa-se que **os valores da média amostral e da mediana são iguais**.
Isso foi coincidência ou sempre teremos $\bar{X} = Md$?

Exemplo

Imagine o seguinte banco de dados: 6, 4, 5, 4, 50

Qual é o valor da mediana ?

Exemplo

Imagine o seguinte banco de dados: 6, 4, 5, 4, 50

Qual é o valor da mediana ?

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{50}}$

Exemplo

Imagine o seguinte banco de dados: 6, 4, 5, 4, 50

Qual é o valor da mediana ?

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{50}}$

Como $n = 5$, então a mediana é dada por

$$Md = x_{(\frac{n+1}{2})} = x_{(\frac{5+1}{2})} = x_3 = 5, 0.$$

Exemplo

Imagine o seguinte banco de dados: 6, 4, 5, 4, 50

Qual é o valor da mediana ?

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{50}}$

Como $n = 5$, então a mediana é dada por

$$Md = x_{(\frac{n+1}{2})} = x_{(\frac{5+1}{2})} = x_3 = 5, 0.$$

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{50}}$

Exemplo

Imagine o seguinte banco de dados: 6, 4, 5, 4, 50

Qual é o valor da mediana ?

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{50}}$

Como $n = 5$, então a mediana é dada por

$$Md = x_{(\frac{n+1}{2})} = x_{(\frac{5+1}{2})} = x_3 = 5, 0.$$

Dados ordenados: $\overset{x_1}{\underbrace{4}}$, $\overset{x_2}{\underbrace{4}}$, $\overset{x_3}{\underbrace{5}}$, $\overset{x_4}{\underbrace{6}}$, $\overset{x_5}{\underbrace{50}}$

Observa-se que os valores da média amostral e da mediana **são diferentes**. Isso significa **um indicativo** de que esse último conjunto de dados possua **pontos influentes** (pontos extremos ou outliers).

Medidas de Dispersão

- Às vezes, tem-se o interesse em resumir um conjunto de dados, apresentando um ou alguns valores que representem todo conjunto de dados
- Exemplos:
 - Aluno A (variável X): 6,4,5,4,6
 - Aluno B (variável Y): 5,5,5,5,5
 - Aluno C (variável Z): 10,10,5,0,0
- Observa-se $\bar{X} = \bar{Y} = \bar{Z} = 5$, porém nada importa sobre suas diferentes variabilidades
- Dessa forma, deve-se construir medidas que sumarizem a variabilidade nos dados. Tais medidas são: **Variância amostral, desvio-padrão amostral e coeficiente de variação.**

Como medir ou quantificar variabilidade ?

Podemos pensar na soma dos **desvios** d_i , isto é, **na diferença de cada valor observado com a média amostral**, ou seja $d_i = x_i - \bar{x}$. Para o exemplo das notas do Aluno A, pode-se calcular os desvios

Como medir ou quantificar variabilidade ?

Podemos pensar na soma dos **desvios** d_i , isto é, **na diferença de cada valor observado com a média amostral**, ou seja $d_i = x_i - \bar{x}$. Para o exemplo das notas do Aluno A, pode-se calcular os desvios

$$d_1 = x_1 - \bar{x} = 6 - 5 = 1$$

Como medir ou quantificar variabilidade ?

Podemos pensar na soma dos **desvios** d_i , isto é, **na diferença de cada valor observado com a média amostral**, ou seja $d_i = x_i - \bar{x}$. Para o exemplo das notas do Aluno A, pode-se calcular os desvios

$$d_1 = x_1 - \bar{x} = 6 - 5 = 1$$

$$d_2 = x_2 - \bar{x} = 4 - 5 = -1$$

Como medir ou quantificar variabilidade ?

Podemos pensar na soma dos **desvios** d_i , isto é, **na diferença de cada valor observado com a média amostral**, ou seja $d_i = x_i - \bar{x}$. Para o exemplo das notas do Aluno A, pode-se calcular os desvios

$$d_1 = x_1 - \bar{x} = 6 - 5 = 1$$

$$d_2 = x_2 - \bar{x} = 4 - 5 = -1$$

$$d_3 = x_3 - \bar{x} = 5 - 5 = 0$$

Como medir ou quantificar variabilidade ?

Podemos pensar na soma dos **desvios** d_i , isto é, **na diferença de cada valor observado com a média amostral**, ou seja $d_i = x_i - \bar{x}$. Para o exemplo das notas do Aluno A, pode-se calcular os desvios

$$d_1 = x_1 - \bar{x} = 6 - 5 = 1$$

$$d_2 = x_2 - \bar{x} = 4 - 5 = -1$$

$$d_3 = x_3 - \bar{x} = 5 - 5 = 0$$

$$d_4 = x_4 - \bar{x} = 4 - 5 = -1$$

Como medir ou quantificar variabilidade ?

Podemos pensar na soma dos **desvios** d_i , isto é, **na diferença de cada valor observado com a média amostral**, ou seja $d_i = x_i - \bar{x}$. Para o exemplo das notas do Aluno A, pode-se calcular os desvios

$$d_1 = x_1 - \bar{x} = 6 - 5 = 1$$

$$d_2 = x_2 - \bar{x} = 4 - 5 = -1$$

$$d_3 = x_3 - \bar{x} = 5 - 5 = 0$$

$$d_4 = x_4 - \bar{x} = 4 - 5 = -1$$

$$d_5 = x_5 - \bar{x} = 6 - 5 = 1$$

Como medir ou quantificar variabilidade ?

Observa-se que a soma dos d_i 's **é igual a zero**, para n observações !!!

Como medir ou quantificar variabilidade ?

Observa-se que a soma dos d_i 's **é igual a zero**, para n observações !!!

$$\sum_{i=1}^n d_i = \sum_{i=1}^n (x_i - \bar{x}) = 0$$

Como medir ou quantificar variabilidade ?

Observa-se que a soma dos d_i 's **é igual a zero**, para n observações !!!

$$\sum_{i=1}^n d_i = \sum_{i=1}^n (x_i - \bar{x}) = 0$$

Uma alternativa, natural, é utilizar o **quadrado dos desvios** e assim computar a variabilidade dos dados por meio da **soma dos quadrados dos desvios**. Temos então,

Como medir ou quantificar variabilidade ?

Observa-se que a soma dos d_i 's é **igual a zero**, para n observações !!!

$$\sum_{i=1}^n d_i = \sum_{i=1}^n (x_i - \bar{x}) = 0$$

Uma alternativa, natural, é utilizar o **quadrado dos desvios** e assim computar a variabilidade dos dados por meio da **soma dos quadrados dos desvios**. Temos então,

$$\sum_{i=1}^n d_i^2 = \sum_{i=1}^n (x_i - \bar{x})^2$$

Como medir ou quantificar variabilidade ?

Observa-se que a soma dos d_i 's é **igual a zero**, para n observações !!!

$$\sum_{i=1}^n d_i = \sum_{i=1}^n (x_i - \bar{x}) = 0$$

Uma alternativa, natural, é utilizar o **quadrado dos desvios** e assim computar a variabilidade dos dados por meio da **soma dos quadrados dos desvios**. Temos então,

$$\sum_{i=1}^n d_i^2 = \sum_{i=1}^n (x_i - \bar{x})^2$$

A utilização desse total **pode causar dificuldades** quando compara-se conjuntos de dados com um número de observações diferentes. Assim, é **mais conveniente exprimir essa quantidade como uma média**, isto é dividindo por $n - 1$.

Variância e desvio-padrão amostrais

- A variância amostral (s^2) fornece a dispersão dos dados em torno do valor central (média)
- Sejam X_1, \dots, X_n , n valores amostrais com média \bar{X} . É definida por

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

- Observa-se que essa quantidade possui uma **medida de dimensão ao quadrado da dimensão dos dados** e assim, pode causar **problemas de interpretação**.
- O **desvio-padrão (s)** é definido como a raiz quadrada da variância
- O desvio-padrão indica, em média, qual será o erro (desvio) cometido ao tentar substituir cada observação pela média

Coeficiente de Variação (CV)

- O CV é uma medida de dispersão relativa utilizada para comparar variáveis.

$$CV = \frac{s}{\bar{X}}$$

- Observa-se que quanto menor for o valor do CV, mais **homogêneo** é um conjunto de dados

Exercício 2

- Considere o conjunto de dados abaixo, com 80 observações, sobre a resistência à compressão de uma liga de Alumínio-Lítio.
- (i) Encontre a tabela de frequências e construa os seguintes gráficos: Histograma e polígono de frequências.
- (ii) Determine a média, variância, moda, mediana e o coeficiente de variação dos dados.

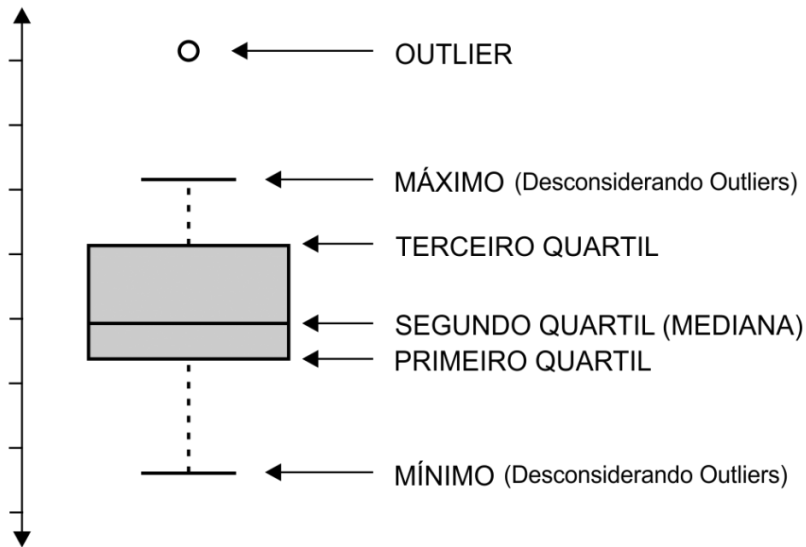
76 ; 120 ; 135 ; 149 ; 157 ; 163 ; 171 ; 178 ; 190 ; 207
87 ; 121 ; 141 ; 150 ; 158 ; 163 ; 171 ; 180 ; 193 ; 208
97 ; 123 ; 142 ; 150 ; 158 ; 165 ; 172 ; 180 ; 194 ; 218
101 ; 131 ; 143 ; 151 ; 158 ; 167 ; 174 ; 181 ; 196 ; 221
105 ; 133 ; 145 ; 153 ; 158 ; 167 ; 174 ; 181 ; 199 ; 228
110 ; 133 ; 146 ; 154 ; 160 ; 168 ; 175 ; 183 ; 199 ; 229
115 ; 134 ; 148 ; 154 ; 160 ; 169 ; 176 ; 184 ; 200 ; 237
118 ; 135 ; 149 ; 156 ; 160 ; 170 ; 176 ; 186 ; 201 ; 245

- Dê forma análoga a mediana, um conjunto de dados pode ser dividido em 4, 10, 100, etc ...
- Quartis: Divide o conjunto de dados em quatro partes iguais

$$\text{Quartis : } \left\{ \begin{array}{ll} Q_1 & \rightarrow 1^{\circ} \text{ Quartil (25\%)} \\ Q_2 & \rightarrow 2^{\circ} \text{ Quartil (50\%)} \\ Q_3 & \rightarrow 3^{\circ} \text{ Quartil (75\%)} \end{array} \right.$$

- $Q_1 = X_{(\frac{n}{4} + \frac{1}{2})}$ e $Q_3 = X_{(\frac{3n}{4} + \frac{1}{2})}$

- É um gráfico construído com base no resumo de cinco medidas, constituído por:
 - Limite mínimo (L_1)
 - 1º Quartil (Q_1)
 - 2º Quartil (Q_2)
 - 3º Quartil (Q_3)
 - Limite máximo (L'_1)
- Para o cálculo do limite mínimo e máximo do boxplot, temos:
 - $L_1 = \max\{x_{min} ; Q_1 - 1,5(Q_3 - Q_1)\}$
 - $L'_1 = \min\{x_{max} ; Q_3 + 1,5(Q_3 - Q_1)\}$
- Por meio do box-plot pode-se verificar: Assimetria nos dados, discutir pontos influentes (possíveis outliers), estudar a variabilidade do conjunto de dados.



Exercício 3

- (a) Utilizando os dados do exemplo 2 (viscosidade num processo químico), construa o gráfico boxplot. Comente sobre a possibilidade de pontos influentes nos dados.
- (b) Utilizando os dados do exercício 2 (resistência à compressão de uma liga de Alumínio-Lítio), construa o gráfico boxplot. Comente sobre a possibilidade de pontos influentes nos dados.

Exercício 4

- Um artigo no *Transactions of the Chemical Engineers* reportou dados sobre um experimento que investigou o efeito de variáveis de processo de oxidação em fase vapor de naftaleno. Uma amostra da conversão percentual molar de naftaleno em anidrido maléico resulta em:

10.20, 12.00, 13.34, 13.54, 13.59, 13.61, 14.06, 14.11, 14.14, 14.17
14.30, 14.62, 14.77, 14.78, 14.85, 15.06, 15.26, 15.55, 15.63, 15.94
16.07, 16.08, 16.12, 16.39, 16.51, 16.78, 17.09, 17.11, 17.26, 17.46
17.59, 17.60, 17.76, 17.78, 18.05, 19.12, 19.18, 19.21, 19.36, 19.38
19.56, 19.70, 20.04, 20.08, 20.35, 20.39, 20.48, 20.67, 20.90, 22.10

- (a) Encontre a média, variância, mediana, os quartis e o coeficiente de variação dos dados brutos.
- (b) Construa o histograma, polígono de frequências e o box-plot.
- (c) Comente sobre a variabilidade, pontos discrepantes e assimetria dos dados acima.