

Teoria da Probabilidade

Rodrigo R. Pescim

Universidade Estadual de Londrina

07 de maio 2020

- *"A razão do número de todos os casos favoráveis à um acontecimento, para o de todos os casos possíveis é a probabilidade buscada, a qual é portanto uma fração $[\cdot \cdot \cdot]$ "*
- *"A teoria da probabilidade nada mais é do que o senso comum reduzido à cálculo."*

Pierre Simon Laplace
Ensaio Filosófico Sobre as Probabilidades (1812)

Teoria da Probabilidade

- É a base sobre a qual a estatística é desenvolvida.

Teoria da Probabilidade

- É a base sobre a qual a estatística é desenvolvida.
- Fornece um meio para modelar populações, experimentos ou **algum fenômeno aleatório** qualquer.

Teoria da Probabilidade

- É a base sobre a qual a estatística é desenvolvida.
- Fornece um meio para modelar populações, experimentos ou **algum fenômeno aleatório** qualquer.
- **objetivo:** Descrever ideias básicas desta teoria, que são fundamentais para o estudo da estatística.

Experimento aleatório (\mathcal{E})

- Um dos maiores objetivos de um estatístico é chegar a conclusões sobre certa população de objetos por meio da **realização de um experimento**.

Experimento aleatório (\mathcal{E})

- Um dos maiores objetivos de um estatístico é chegar a conclusões sobre certa população de objetos por meio da **realização de um experimento**.
- Um experimento é qualquer processo de observação.

Experimento aleatório (\mathcal{E})

- Um dos maiores objetivos de um estatístico é chegar a conclusões sobre certa população de objetos por meio da **realização de um experimento**.
- Um experimento é qualquer processo de observação.
- Em muitos experimentos, **observa-se um elemento de incerteza** e essencialmente a **impossibilidade** de prever seu comportamento em futuras realizações.

Experimento aleatório (\mathcal{E})

- Um dos maiores objetivos de um estatístico é chegar a conclusões sobre certa população de objetos por meio da **realização de um experimento**.
- Um experimento é qualquer processo de observação.
- Em muitos experimentos, **observa-se um elemento de incerteza** e essencialmente a **impossibilidade** de prever seu comportamento em futuras realizações.
- **objetivo:** Descrever ideias básicas desta teoria, que são fundamentais para o estudo da estatística.

Razões para a nossa falta de habilidade em prever:

- Pode-se **não ter conhecimento** de todas as causas envolvidas;

Razões para a nossa falta de habilidade em prever:

- Pode-se **não ter conhecimento** de todas as causas envolvidas;
- Pode-se não ter **dados suficientes** sobre as condições iniciais do experimento;

Razões para a nossa falta de habilidade em prever:

- Pode-se **não ter conhecimento** de todas as causas envolvidas;
- Pode-se não ter **dados suficientes** sobre as condições iniciais do experimento;
- As **causas podem ser tão complexas** que o cálculo do seu efeito combinado não é possível;

Razões para a nossa falta de habilidade em prever:

- Pode-se **não ter conhecimento** de todas as causas envolvidas;
- Pode-se não ter **dados suficientes** sobre as condições iniciais do experimento;
- As **causas podem ser tão complexas** que o cálculo do seu efeito combinado não é possível;
- **Existe alguma aleatoriedade** fundamental no experimento

Estaremos interessados em uma classe particular de experimentos, chamados **experimentos aleatórios**.

Um experimento aleatório é caracterizado por:

Um experimento aleatório é caracterizado por:

1. Repete-se, **sob as mesmas condições**, o experimento e seus resultados em diferentes realizações **podem ser diferentes**.

Um experimento aleatório é caracterizado por:

1. Repete-se, **sob as mesmas condições**, o experimento e seus resultados em diferentes realizações **podem ser diferentes**.
 - **Exemplo 1:** Jogar uma moeda diversas vezes com bastante cuidado para que cada jogada seja realizada da mesma maneira.

Um experimento aleatório é caracterizado por:

1. Repete-se, **sob as mesmas condições**, o experimento e seus resultados em diferentes realizações **podem ser diferentes**.
 - **Exemplo 1:** Jogar uma moeda diversas vezes com bastante cuidado para que cada jogada seja realizada da mesma maneira.
2. Apesar de não ser capaz de afirmar que resultado particular ocorre, pode-se descrever o **conjunto de todos os possíveis resultados** do experimento.

Um experimento aleatório é caracterizado por:

1. Repete-se, **sob as mesmas condições**, o experimento e seus resultados em diferentes realizações **podem ser diferentes**.
 - **Exemplo 1:** Jogar uma moeda diversas vezes com bastante cuidado para que cada jogada seja realizada da mesma maneira.
2. Apesar de não ser capaz de afirmar que resultado particular ocorre, pode-se descrever o **conjunto de todos os possíveis resultados** do experimento.
3. Ao repetir o experimento um grande número de vezes, pode-se observar uma certa **regularidade**. É esta regularidade que torna possível construir um **modelo probabilístico**.

Um experimento aleatório é caracterizado por:

1. Repete-se, **sob as mesmas condições**, o experimento e seus resultados em diferentes realizações **podem ser diferentes**.
 - **Exemplo 1:** Jogar uma moeda diversas vezes com bastante cuidado para que cada jogada seja realizada da mesma maneira.
2. Apesar de não ser capaz de afirmar que resultado particular ocorre, pode-se descrever o **conjunto de todos os possíveis resultados** do experimento.
3. Ao repetir o experimento um grande número de vezes, pode-se observar uma certa **regularidade**. É esta regularidade que torna possível construir um **modelo probabilístico**.
 - **Retornando ao exemplo 1:** É fato empírico conhecido que, depois de um grande número de jogadas, **a proporção de caras e de coroas serão aproximadamente iguais** (assumindo que a moeda é simétrica).

Exemplos de experimentos aleatórios

\mathcal{E}_1 : Lançamento de uma moeda honesta;

\mathcal{E}_2 : Lançamento de um dado honesto;

\mathcal{E}_3 : Lançamento de duas moedas honestas;

\mathcal{E}_4 : Selecionar um morador da cidade de Londrina e medir sua altura;

\mathcal{E}_5 : Observar o tempo de falha de um componente mecânico;

\mathcal{E}_6 : Número peças defeituosas num processo de fabricação

Espaço Amostral (Ω)

- O **espaço amostral** é o conjunto de todos os resultados possíveis associados a um experimento aleatório (ε), representado por Ω .
- Dos exemplos anteriores temos:

Espaço Amostral (Ω)

- O **espaço amostral** é o conjunto de todos os resultados possíveis associados a um experimento aleatório (ε), representado por Ω .
- Dos exemplos anteriores temos:
 ε_1 : $\Omega_1 = \{C, K\}$, em que $C = \text{cara}$ e $K = \text{coroa}$

Espaço Amostral (Ω)

- O **espaço amostral** é o conjunto de todos os resultados possíveis associados a um experimento aleatório (ε), representado por Ω .
- Dos exemplos anteriores temos:
 - ε_1 : $\Omega_1 = \{C, K\}$, em que $C = \text{cara}$ e $K = \text{coroa}$
 - ε_2 : $\Omega_2 = \{1, 2, 3, 4, 5, 6\}$, em que $i = 1, \dots, 6$ são as faces

Espaço Amostral (Ω)

- O **espaço amostral** é o conjunto de todos os resultados possíveis associados a um experimento aleatório (ε), representado por Ω .
- Dos exemplos anteriores temos:
 - ε_1 : $\Omega_1 = \{C, K\}$, em que $C = \text{cara}$ e $K = \text{coroa}$
 - ε_2 : $\Omega_2 = \{1, 2, 3, 4, 5, 6\}$, em que $i = 1, \dots, 6$ são as faces
 - ε_3 : $\Omega_3 = \{(C, C), (C, K), (K, C), (K, K)\}$;

Espaço Amostral (Ω)

- O **espaço amostral** é o conjunto de todos os resultados possíveis associados a um experimento aleatório (ε), representado por Ω .
- Dos exemplos anteriores temos:
 - ε_1 : $\Omega_1 = \{C, K\}$, em que $C = \text{cara}$ e $K = \text{coroa}$
 - ε_2 : $\Omega_2 = \{1, 2, 3, 4, 5, 6\}$, em que $i = 1, \dots, 6$ são as faces
 - ε_3 : $\Omega_3 = \{(C, C), (C, K), (K, C), (K, K)\}$;
 - ε_4 : $\Omega_4 = \{h \in \mathbb{R}, h > 0\}$

Espaço Amostral (Ω)

- O **espaço amostral** é o conjunto de todos os resultados possíveis associados a um experimento aleatório (ε), representado por Ω .
- Dos exemplos anteriores temos:
 - ε_1 : $\Omega_1 = \{C, K\}$, em que $C = \text{cara}$ e $K = \text{coroa}$
 - ε_2 : $\Omega_2 = \{1, 2, 3, 4, 5, 6\}$, em que $i = 1, \dots, 6$ são as faces
 - ε_3 : $\Omega_3 = \{(C, C), (C, K), (K, C), (K, K)\}$;
 - ε_4 : $\Omega_4 = \{h \in \mathbb{R}, h > 0\}$
 - ε_5 : $\Omega_5 = \{t \in \mathbb{R}, t > 0\}$

Espaço Amostral (Ω)

- O **espaço amostral** é o conjunto de todos os resultados possíveis associados a um experimento aleatório (ε), representado por Ω .
- Dos exemplos anteriores temos:
 - ε_1 : $\Omega_1 = \{C, K\}$, em que $C = \text{cara}$ e $K = \text{coroa}$
 - ε_2 : $\Omega_2 = \{1, 2, 3, 4, 5, 6\}$, em que $i = 1, \dots, 6$ são as faces
 - ε_3 : $\Omega_3 = \{(C, C), (C, K), (K, C), (K, K)\}$;
 - ε_4 : $\Omega_4 = \{h \in \mathbb{R}, h > 0\}$
 - ε_5 : $\Omega_5 = \{t \in \mathbb{R}, t > 0\}$
 - ε_6 : $\Omega_6 = \{0, 1, 2, 3, 4, \dots\}$

Tipos de Espaço Amostral

- Podemos classificar espaços amostrais em dois tipos de acordo com os elementos que eles contém.
- Espaços amostrais podem ser **enumeráveis** ou **não enumeráveis**.
- Se os elementos do espaço amostral podem ser colocados em **uma correspondência 1-1** com um subconjunto dos inteiros, o espaço amostral é **enumerável**.

Em um nível filosófico, pode-se argumentar que **só existem espaços amostrais enumeráveis**, visto que **medidas não podem ser realizadas com infinita precisão**. Enquanto na prática isto é verdadeiro, métodos estatísticos e probabilísticos associados com espaços amostrais não enumeráveis são, em geral, menos complicados que aqueles para espaços amostrais enumeráveis, e proporcionam uma boa aproximação para a situação (enumerável) real.

- Um **evento** é um subconjunto do espaço amostral, ou seja, é um conjunto de resultados possíveis do experimento aleatório.
- Se ao realizarmos um experimento aleatório, o resultado pertence a um dado evento A , dizemos que A **ocorreu**.
- Estaremos interessados no estudo da ocorrência de combinações de eventos. Para isso, pode-se utilizar as **operações Booleanas de conjuntos** (complementar, união, intersecção, diferença) para expressar eventos combinados de interesse.

Definição 1. Os eventos A e B são **disjuntos** ou **mutuamente exclusivos** se a intersecção entre eles é vazia, isto é, $A \cap B = \emptyset$.

Exemplo 1: Sejam A , B , e C eventos em um mesmo espaço amostral Ω . Expresse os seguintes eventos em função de A , B , e C e operações Booleanas de conjuntos.

- (a) Pelo menos um deles ocorre.
- (b) Exatamente um deles ocorre.
- (c) Apenas A ocorre.
- (d) Pelo menos dois ocorrem.
- (e) No máximo dois deles ocorrem.
- (f) Nenhum deles ocorre.
- (g) Ambos A e B ocorrem, mas C não ocorre.

(a) $(A \cup B \cup C)$

(a) $(A \cup B \cup C)$

(b) $(A \cap B^c \cap C^c) \cup (A^c \cap B \cap C^c) \cup (A^c \cap B^c \cap C)$

(a) $(A \cup B \cup C)$

(b) $(A \cap B^c \cap C^c) \cup (A^c \cap B \cap C^c) \cup (A^c \cap B^c \cap C)$

(c) $(A \cap B^c \cap C^c)$

(a) $(A \cup B \cup C)$

(b) $(A \cap B^c \cap C^c) \cup (A^c \cap B \cap C^c) \cup (A^c \cap B^c \cap C)$

(c) $(A \cap B^c \cap C^c)$

(d) $(A \cap B \cap C^c) \cup (A \cap B^c \cap C) \cup (A^c \cap B \cap C) \cup (A \cap B \cap C)$

(a) $(A \cup B \cup C)$

(b) $(A \cap B^c \cap C^c) \cup (A^c \cap B \cap C^c) \cup (A^c \cap B^c \cap C)$

(c) $(A \cap B^c \cap C^c)$

(d) $(A \cap B \cap C^c) \cup (A \cap B^c \cap C) \cup (A^c \cap B \cap C) \cup (A \cap B \cap C)$

(e) $(A \cap B \cap C)^c$

(a) $(A \cup B \cup C)$

(b) $(A \cap B^c \cap C^c) \cup (A^c \cap B \cap C^c) \cup (A^c \cap B^c \cap C)$

(c) $(A \cap B^c \cap C^c)$

(d) $(A \cap B \cap C^c) \cup (A \cap B^c \cap C) \cup (A^c \cap B \cap C) \cup (A \cap B \cap C)$

(e) $(A \cap B \cap C)^c$

(f) $(A^c \cap B^c \cap C^c)$

(a) $(A \cup B \cup C)$

(b) $(A \cap B^c \cap C^c) \cup (A^c \cap B \cap C^c) \cup (A^c \cap B^c \cap C)$

(c) $(A \cap B^c \cap C^c)$

(d) $(A \cap B \cap C^c) \cup (A \cap B^c \cap C) \cup (A^c \cap B \cap C) \cup (A \cap B \cap C)$

(e) $(A \cap B \cap C)^c$

(f) $(A^c \cap B^c \cap C^c)$

(g) $(A \cap B \cap C^c)$

Leis de Morgan

$$(i) \left(\bigcup_{i=1}^{\infty} A_i \right)^c = \bigcap_{i=1}^{\infty} A_i^c$$

$$(ii) \left(\bigcap_{i=1}^{\infty} A_i \right)^c = \bigcup_{i=1}^{\infty} A_i^c$$

Observa-se que (i) e (ii) são chamadas de Leis de Morgan.

$$(iii) A \cap \left(\bigcup_{i=1}^{\infty} B_i \right) = \bigcup_{i=1}^{\infty} (A \cap B_i)$$

$$(iv) A \cup \left(\bigcap_{i=1}^{\infty} B_i \right) = \bigcap_{i=1}^{\infty} (A \cup B_i)$$

Definição 2. Dado um espaço amostral Ω , **uma partição** $\Pi = \{A_i, i \in \mathbb{N}\}$ de Ω é uma **coleção de eventos** (subconjuntos de Ω) e satisfaz:

P1. $A_i \cap A_j = \emptyset, \forall i \neq j.$

P2. $\bigcup_{i \in \mathbb{N}} A_i = \Omega.$

Definição 2. Dado um espaço amostral Ω , **uma partição** $\Pi = \{A_i, i \in \mathbb{N}\}$ de Ω é uma **coleção de eventos** (subconjuntos de Ω) e satisfaz:

P1. $A_i \cap A_j = \emptyset, \forall i \neq j.$

P2. $\bigcup_{i \in \mathbb{N}} A_i = \Omega.$

Observação: Deste modo os eventos de uma partição são **mutuamente exclusivos** e **cobrem todo o espaço amostral**. Portanto, cada elemento $\omega \in \Omega$ pertence a um, e somente um, dos eventos A_i de uma partição.

Definição 2. Dado um espaço amostral Ω , **uma partição** $\Pi = \{A_i, i \in \mathbb{N}\}$ de Ω é uma **coleção de eventos** (subconjuntos de Ω) e satisfaz:

P1. $A_i \cap A_j = \emptyset, \forall i \neq j.$

P2. $\bigcup_{i \in \mathbb{N}} A_i = \Omega.$

Observação: Deste modo os eventos de uma partição são **mutuamente exclusivos** e **cobrem todo o espaço amostral**. Portanto, cada elemento $\omega \in \Omega$ pertence a um, e somente um, dos eventos A_i de uma partição.

Exemplo 2: Seja $\Omega = \{1, 2, 3, 4\}$ um espaço amostral e considere $A_1 = \{1, 2, 3\}$ e $A_2 = \{4\}$ eventos. A_1 e A_2 formam uma partição de Ω ?

Definição 2. Dado um espaço amostral Ω , **uma partição** $\Pi = \{A_i, i \in \mathbb{N}\}$ de Ω é uma **coleção de eventos** (subconjuntos de Ω) e satisfaz:

P1. $A_i \cap A_j = \emptyset, \forall i \neq j.$

P2. $\bigcup_{i \in \mathbb{N}} A_i = \Omega.$

Observação: Deste modo os eventos de uma partição são **mutuamente exclusivos** e **cobrem todo o espaço amostral**. Portanto, cada elemento $\omega \in \Omega$ pertence a um, e somente um, dos eventos A_i de uma partição.

Exemplo 2: Seja $\Omega = \{1, 2, 3, 4\}$ um espaço amostral e considere $A_1 = \{1, 2, 3\}$ e $A_2 = \{4\}$ eventos. A_1 e A_2 formam uma partição de Ω ?

Exemplo 3: A coleção de intervalos $\{(n, n + 1] : n \in \mathbb{Z}\}$ é uma partição dos números reais \mathbb{R} ?

Sigma-álgebra (ou σ -álgebra) de Eventos

Embora possa-se pensar que, para certo um Ω , necessariamente é de interesse analisar todos os seus subconjuntos (e isto eventualmente é verdadeiro), temos três razões para considerar alguns subconjuntos de Ω .

Sigma-álgebra (ou σ -álgebra) de Eventos

Embora possa-se pensar que, para certo um Ω , necessariamente é de interesse analisar todos os seus subconjuntos (e isto eventualmente é verdadeiro), temos três razões para considerar alguns subconjuntos de Ω .

1. O espaço amostral pode conter um grau de detalhamento superior ao que estamos interessados.

Sigma-álgebra (ou σ -álgebra) de Eventos

Embora possa-se pensar que, para certo um Ω , necessariamente é de interesse analisar todos os seus subconjuntos (e isto eventualmente é verdadeiro), temos três razões para considerar alguns subconjuntos de Ω .

1. O espaço amostral pode conter um grau de detalhamento superior ao que estamos interessados.
2. Pode-se associar cada evento A com uma probabilidade $P(A)$. Como essas probabilidades estão baseadas em algum conhecimento sobre a ocorrência do evento A , nosso conhecimento sobre P **pode não estender para todos os subconjuntos de Ω .**

Sigma-álgebra (ou σ -álgebra) de Eventos

Embora possa-se pensar que, para certo um Ω , necessariamente é de interesse analisar todos os seus subconjuntos (e isto eventualmente é verdadeiro), temos três razões para considerar alguns subconjuntos de Ω .

1. O espaço amostral pode conter um grau de detalhamento superior ao que estamos interessados.
2. Pode-se associar cada evento A com uma probabilidade $P(A)$. Como essas probabilidades estão baseadas em algum conhecimento sobre a ocorrência do evento A , nosso conhecimento sobre P **pode não estender para todos os subconjuntos de Ω .**
3. Existem condições em P pelos **axiomas de Kolmogorov**, que estudaremos adiante, que podem não permitir que P **seja definida em todos os subconjuntos de Ω** , em particular isto pode ocorrer quando Ω for não enumerável. (Resultado da **Teoria da Medida**).

Sigma-álgebra (ou σ -álgebra) de Eventos

Estamos interessados em uma **coleção \mathcal{F} de subconjuntos de Ω** (note que \mathcal{F} é um conjunto cujos elementos também são conjuntos!) que são eventos de interesse no que se refere ao experimento aleatório \mathcal{E} e os quais **temos conhecimento sobre a sua probabilidade de ocorrência**. \mathcal{F} é chamado de uma **σ -álgebra de eventos**.

Sigma-álgebra (ou σ -álgebra) de Eventos

Estamos interessados em uma **coleção \mathcal{F} de subconjuntos de Ω** (note que \mathcal{F} é um conjunto cujos elementos também são conjuntos!) que são eventos de interesse no que se refere ao experimento aleatório \mathcal{E} e os quais **temos conhecimento sobre a sua probabilidade de ocorrência**. \mathcal{F} é chamado de uma **σ -álgebra de eventos**.

Definição 3. Uma σ -álgebra de eventos \mathcal{F} é uma coleção de subconjuntos de Ω que satisfaz:

1. $\Omega \in \mathcal{F}$;
2. Se $A \in \mathcal{F}$ então $A^c \in \mathcal{F}$;
3. Se $A_i \in \mathcal{F}$, com $i \in \mathbb{N}$, então $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$.

1. $\mathcal{F} = \{\emptyset, \Omega\}$ é σ -álgebra?
2. $\mathcal{F} = \{\emptyset, A, A^c, \Omega\}$ é σ -álgebra?
3. Considere $\Omega = \{1, 2, 3\}$ e as seguintes coleções:
 $\mathcal{F}_1 = \{\emptyset, \Omega, \{1\}, \{2, 3\}\}$ e $\mathcal{F}_2 = \{\emptyset, \Omega, \{1\}, \{2\}, \{1, 3\}, \{2, 3\}\}$.
 \mathcal{F}_1 e \mathcal{F}_2 são σ -álgebras? Justifique.
4. Sejam $\Omega = [0, 1] \cap \mathbb{R}$ um espaço amostral e \mathcal{F}_1 e \mathcal{F}_2 duas sigma-álgebras em Ω . Mostre que $\mathcal{F} = \{A : A \in \mathcal{F}_1 \cap \mathcal{F}_2\}$ é uma sigma-álgebra, mas $\mathcal{G} = \{A : A \in \mathcal{F}_1 \cup \mathcal{F}_2\}$ não é.

Exemplo: σ -álgebra de Borel

Seja $\Omega = \mathbb{R}$. A σ -álgebra de Borel, denotada por $\mathcal{B}(\mathbb{R})$, é se define como a **menor σ -álgebra** de subconjuntos de \mathbb{R} que contém todos os intervalos da seguinte forma: $(-\infty, x]$, $x \in \mathbb{R}$.

Exemplo: σ -álgebra de Borel

Seja $\Omega = \mathbb{R}$. A σ -álgebra de Borel, denotada por $\mathcal{B}(\mathbb{R})$, é se define como a **menor σ -álgebra** de subconjuntos de \mathbb{R} que contém todos os intervalos da seguinte forma: $(-\infty, x]$, $x \in \mathbb{R}$.

Observações:

- Pode-se mostrar que nem todos os subconjuntos de \mathbb{R} estão em $\mathcal{B}(\mathbb{R})$.
- De maneira análoga, pode-se definir $\mathcal{B}(\mathbb{R}^2), \mathcal{B}(\mathbb{R}^3), \dots, \mathcal{B}(\mathbb{R}^n)$
- Em geral, todas as questões de interesse na teoria da probabilidade se referem a σ -álgebra de Borel.

Pode-se classificar os fundamentos da probabilidade nas seguintes situações:

- O **grau de precisão**, isto é o que podemos esperar da probabilidade como representação dos fenômenos aleatórios.
- A **interpretação** que proporciona a base com a qual probabilidade deve ser determinada.
- A **estrutura matemática** formal de probabilidade dada por um conjunto de axiomas.

Observação:

A compreensão dos **fundamentos de probabilidade** é importante, pois esses fundamentos influenciam na escolha dos **métodos estatísticos** a serem utilizados (Clássicos/Frequentistas, Logicista, Bayesianos, etc).

Interpretação Clássica de Probabilidade

- i) Cardano (1663), De Moivre (1718), Laplace (1812)
- ii) A probabilidade é definida com base em dados do experimento aleatório. Além disso, baseia-se no conceito de **resultados equiprováveis**;
- iii) Observa-se que todo evento de Ω tem uma probabilidade.

Interpretação Clássica de Probabilidade

- i) Cardano (1663), De Moivre (1718), Laplace (1812)
- ii) A probabilidade é definida com base em dados do experimento aleatório. Além disso, baseia-se no conceito de **resultados equiprováveis**;
- iii) Observa-se que todo evento de Ω tem uma probabilidade.

Dado um espaço amostral Ω , a probabilidade de um evento A , tal que $A \in \mathcal{F} = \mathcal{P}(\Omega)$, que associa um valor numérico ao evento A é definida por

$$P(A) = \frac{\#A}{\#\Omega} = \frac{\text{nº de resultados favoráveis do evento } A}{\text{nº de resultados possíveis}}$$

Interpretação Frequentista de Probabilidade

- i) John Venn (1866), Von Mises (1928)
- ii) Pode-se **repetir** o experimento aleatório n vezes;
- iii) E assim contar quantas vezes o evento A ocorre, $n(A)$ (número de ocorrências de A).

Dessa forma a **frequência relativa de A** nas n repetições é dada por

$$f_n(A) = \frac{n(A)}{n}.$$

Para $n \rightarrow \infty$ repetições sucessivas e independentes, a frequência relativa de A tende para uma constante p

$$\lim_{n \rightarrow \infty} f_n(A) = \lim_{n \rightarrow \infty} \frac{n(A)}{n} = P(A) = p$$

Exemplo: Se um dado fosse lançado **10** vezes, e contássemos quantas vezes saiu a face 4, qual seria a probabilidade desse evento?

```
## Tamanho da amostra
```

```
n <- 10
```

```
## Objeto para armazenar os resultados
```

```
x <- numeric(n)
```

```
## Estrutura de repetição
```

```
# Repetir n vezes
```

```
for(i in 1:n){
```

```
# Amostra aleatória de tamanho 1 dos números 1 a 6
```

```
x[i] <- sample(1:6, size = 1)
```

```
}
```

```
## Total de valores igual a 4 => n(A)
```

```
sum(x == 4)
```

```
[1] 3
```

```
## Proporção de valores igual a 4 => n(A)/n
```

```
sum(x == 4)/length(x)
```

```
[1] 0.3
```

Exemplo: Se um dado fosse lançado **100** vezes, e contássemos quantas vezes saiu a face 4, qual seria a probabilidade desse evento?

```
## Tamanho da amostra
```

```
n <- 100
```

```
## Objeto para armazenar os resultados
```

```
x <- numeric(n)
```

```
## Estrutura de repetição
```

```
# Repetir n vezes
```

```
for(i in 1:n){
```

```
# Amostra aleatória de tamanho 1 dos números 1 a 6
```

```
x[i] <- sample(1:6, size = 1)
```

```
}
```

```
## Total de valores igual a 4 => n(A)
```

```
sum(x == 4)
```

```
[1] 13
```

```
## Proporção de valores igual a 4 => n(A)/n
```

```
sum(x == 4)/length(x)
```

```
[1] 0.13
```

Exemplo: Se um dado fosse lançado **1000** vezes, e contássemos quantas vezes saiu a face 4, qual seria a probabilidade desse evento?

```
## Tamanho da amostra
```

```
n <- 1000
```

```
## Objeto para armazenar os resultados
```

```
x <- numeric(n)
```

```
## Estrutura de repetição
```

```
# Repetir n vezes
```

```
for(i in 1:n){
```

```
# Amostra aleatória de tamanho 1 dos números 1 a 6
```

```
x[i] <- sample(1:6, size = 1)
```

```
}
```

```
## Total de valores igual a 4 => n(A)
```

```
sum(x == 4)
```

```
[1] 146
```

```
## Proporção de valores igual a 4 => n(A)/n
```

```
sum(x == 4)/length(x)
```

```
[1] 0.146
```

Exemplo: Se um dado fosse lançado **10000** vezes, e contássemos quantas vezes saiu a face 4, qual seria a probabilidade desse evento?

```
## Tamanho da amostra
```

```
n <- 10000
```

```
## Objeto para armazenar os resultados
```

```
x <- numeric(n)
```

```
## Estrutura de repetição
```

```
# Repetir n vezes
```

```
for(i in 1:n){
```

```
# Amostra aleatória de tamanho 1 dos números 1 a 6
```

```
x[i] <- sample(1:6, size = 1)
```

```
}
```

```
## Total de valores igual a 4 => n(A)
```

```
sum(x == 4)
```

```
[1] 1586
```

```
## Proporção de valores igual a 4 => n(A)/n
```

```
sum(x == 4)/length(x)
```

```
[1] 0.1586
```

Exemplo: Se um dado fosse lançado **100000** vezes, e contássemos quantas vezes saiu a face 4, qual seria a probabilidade desse evento?

```
## Tamanho da amostra
```

```
n <- 100000
```

```
## Objeto para armazenar os resultados
```

```
x <- numeric(n)
```

```
## Estrutura de repetição
```

```
# Repetir n vezes
```

```
for(i in 1:n){
```

```
# Amostra aleatória de tamanho 1 dos números 1 a 6
```

```
x[i] <- sample(1:6, size = 1)
```

```
}
```

```
## Total de valores igual a 4 => n(A)
```

```
sum(x == 4)
```

```
[1] 16616
```

```
## Proporção de valores igual a 4 => n(A)/n
```

```
sum(x == 4)/length(x)
```

```
[1] 0.16616
```

Exemplo: Se um dado fosse lançado **1000000** vezes, e contássemos quantas vezes saiu a face 4, qual seria a probabilidade desse evento?

```
## Tamanho da amostra
```

```
n <- 1000000
```

```
## Objeto para armazenar os resultados
```

```
x <- numeric(n)
```

```
## Estrutura de repetição
```

```
# Repetir n vezes
```

```
for(i in 1:n){
```

```
# Amostra aleatória de tamanho 1 dos números 1 a 6
```

```
x[i] <- sample(1:6, size = 1)
```

```
}
```

```
## Total de valores igual a 4 => n(A)
```

```
sum(x == 4)
```

```
[1] 166911
```

```
## Proporção de valores igual a 4 => n(A)/n
```

```
sum(x == 4)/length(x)
```

```
[1] 0.16691
```

Assim,

$$\lim_{n \rightarrow \infty} f_n(A) = \lim_{n \rightarrow \infty} \frac{n(A)}{n} = P(A) \approx 0,1667$$

As probabilidades calculadas a partir de **frequências relativas**, são **estimativas** da verdadeira probabilidade.

Observação

Nós prosseguiremos como se existisse alguma **base empírica** (ou metafísica) que garanta que $f_n(A) \rightarrow P(A)$, embora que o sentido de convergência quando n cresce só será explicado pela **Lei dos Grandes Números**. Esta tendência da frequência relativa de estabilizar em um certo valor é conhecida como **regularidade estatística**.

Interpretação de Probabilidade

- ❶ **Clássica:** Baseada em uma enumeração de casos *igualmente prováveis*.

Interpretação de Probabilidade

- i) **Clássica:** Baseada em uma enumeração de casos *igualmente prováveis*.
- ii) **Frequentista:** Se refere ao limite da frequência relativa de ocorrência do evento A *em repetidas realizações independentes* do experimento aleatório ε .

Interpretação de Probabilidade

- i) **Clássica:** Baseada em uma enumeração de casos *igualmente prováveis*.
- ii) **Frequentista:** Se refere ao limite da frequência relativa de ocorrência do evento A *em repetidas realizações independentes* do experimento aleatório ε .
- iii) **Subjetiva:** Se refere ao grau de crença pessoal na ocorrência do evento A e é medida por meio da interpretação comportamental de disposição a apostar ou agir.

Interpretação de Probabilidade

- i) **Clássica:** Baseada em uma enumeração de casos *igualmente prováveis*.
- ii) **Frequentista:** Se refere ao limite da frequência relativa de ocorrência do evento A *em repetidas realizações independentes* do experimento aleatório ε .
- iii) **Subjetiva:** Se refere ao grau de crença pessoal na ocorrência do evento A e é medida por meio da interpretação comportamental de disposição a apostar ou agir.
- iv) **Lógica:** É o grau de confirmação da hipótese de uma proposição que “ A ocorre” dada uma evidência por meio da proposição que “ B ocorreu”.

Interpretação de Probabilidade

- i) **Clássica:** Baseada em uma enumeração de casos *igualmente prováveis*.
- ii) **Frequentista:** Se refere ao limite da frequência relativa de ocorrência do evento A *em repetidas realizações independentes* do experimento aleatório ε .
- iii) **Subjetiva:** Se refere ao grau de crença pessoal na ocorrência do evento A e é medida por meio da interpretação comportamental de disposição a apostar ou agir.
- iv) **Lógica:** É o grau de confirmação da hipótese de uma proposição que “ A ocorre” dada uma evidência por meio da proposição que “ B ocorreu”.
- v) **Geométrica:** É uma interpretação relacionada com quantidades geométricas, isto é, dois eventos A e B possuem a mesma probabilidade se, e somente se, eles têm a mesma área.

- Os axiomas que descreveremos a seguir não descrevem um único modelo probabilístico, eles apenas determinam uma família de **modelos probabilísticos**.

- Os axiomas que descreveremos a seguir não descrevem um único modelo probabilístico, eles apenas determinam uma família de **modelos probabilísticos**.
- A escolha de um **modelo específico satisfazendo os axiomas** é realizado por meio do **fenômeno aleatório** que está sendo estudado.

- Os axiomas que descrevermos a seguir não descrevem um único modelo probabilístico, eles apenas determinam uma família de **modelos probabilísticos**.
- A escolha de um **modelo específico satisfazendo os axiomas** é realizado por meio do **fenômeno aleatório** que está sendo estudado.
- Motivado pelas propriedades de frequência relativa, **Andrei Kolmogorov** propõe, em 1933, **a axiomatização do conceito de probabilidade** por meio de três axiomas.

Definição 4. Uma função P , definida na σ -álgebra \mathcal{F} de subconjuntos de Ω e com valores em $[0, 1]$, $P : \mathcal{F} \rightarrow [0, 1]$ é uma **medida de probabilidade** se satisfaz os axiomas de Kolmogorov:

1. **Normalização Unitária.** $P(\Omega) = 1$;
2. **Não-negatividade.** $\forall A \in \mathcal{F}, P(A) \geq 0$;
3. **σ -aditividade.** $\forall A_1, A_2, A_3, \dots \in \mathcal{F}$ então
$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i),$$
 sendo disjuntos dois a dois.

Observações:

1. Motivado pelas propriedades de frequência relativa (**interpretação frequentista de probabilidade**), Andrei Kolmogorov por volta de 1933, propôs os axiomas acima.
2. Os axiomas de Kolmogorov não descrevem um único modelo probabilístico, eles apenas **determinam uma família de modelos probabilísticos**, com os quais pode-se utilizar métodos matemáticos para estudar propriedades **que serão verdadeiras em qualquer modelo probabilístico**.
3. Assim, a escolha de um modelo específico **satisfazendo os axiomas de Kolmogorov** é feito pelo probabilista/estatístico familiar com o fenômeno aleatório que está sendo modelado.

Definição 5. Seja ε um **experimento aleatório** associado ao **espaço amostral** Ω . Suponhamos que \mathcal{F} é uma σ -álgebra de subconjuntos de Ω onde se pode definir uma medida de probabilidade P , isto é, $P : \mathcal{F} \rightarrow [0, 1]$. Então, a trinca (Ω, \mathcal{F}, P) chama-se **espaço de probabilidade** e representa um **modelo probabilístico**.

Espaço de Probabilidade

Definição 5. Seja ε um **experimento aleatório** associado ao **espaço amostral** Ω . Suponhamos que \mathcal{F} é uma σ -álgebra de subconjuntos de Ω onde se pode definir uma medida de probabilidade P , isto é, $P : \mathcal{F} \rightarrow [0, 1]$. Então, a trinca (Ω, \mathcal{F}, P) chama-se **espaço de probabilidade** e representa um **modelo probabilístico**.

Observações:

1. Intuitivamente quando se propõe um modelo para um problema por meio de probabilidade, basicamente, o que se faz é especificar cada uma das componentes da trinca acima.
2. Eventos são os elementos de \mathcal{F} , aos quais se pode atribuir probabilidade. Assim, probabilidade é uma função cujo argumento é um conjunto.
3. Portanto, não somente conjuntos, como também as operações sobre eles, têm uma importância fundamental em teoria da probabilidade.

Exemplo 1. Se Ω for um conjunto finito, então temos que a probabilidade clássica que assume que todos os resultados são igualmente prováveis, é um exemplo de uma medida de probabilidade. Neste caso, temos que

$$P(A) = \frac{||A||}{||\Omega||},$$

definido para todo A subconjunto de Ω . O fato de $0 \leq ||A|| \leq ||\Omega||$ e que

$$||A \cup B|| = ||A|| + ||B|| - ||A \cap B||,$$

permitem que P satisfaça os axiomas de Kolmogorov.

Exemplo 2. Seja $\Omega = \{\omega_1, \omega_1, \dots, \omega_n\}$ um conjunto finito e considere $P(\{\omega_i\}) = p_i$ em que $i \geq 1$. Além disso, vamos admitir que $\sum_{i=1}^n p_i = 1$.

A probabilidade de um evento A é dada por

$$P(A) = \sum_{\omega_i \in A} P(\{\omega_i\}).$$

Pode-se notar que P é uma medida de probabilidade, verificando os axiomas de Kolmogorov.

Exemplo 3. Seja $\Omega = [0, 1]$ e \mathcal{B}_0 a σ -álgebra de Borel restrita a eventos contidos em $[0, 1]$. Pode-se mostrar que existe uma medida de probabilidade μ em (Ω, \mathcal{B}_0) tal que para todo intervalo I em $[0, 1]$, $\mu(I)$ é igual ao comprimento I . Esta medida de probabilidade μ é conhecida como **medida de Lebesgue**.

Propriedades de uma Medida de Probabilidade

Teorema 1: Seja A um evento de Ω qualquer e P uma medida de probabilidade. Então,

P1. $P(A^c) = 1 - P(A)$;

P2. $P(\emptyset) = 0$;

P3. $P(A) \leq 1$.

Teorema 2: Monotonicidade. Se $A \subseteq B$ então $P(A) \leq P(B)$.

Teorema 3: Uma expressão exata para a probabilidade de uma união não-disjunta é dada por

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Teorema 4: Probabilidade de Partições. Seja $\{A_i\}$ uma partição enumerável de Ω , de conjuntos em \mathcal{F} . Então, para todo $B \in \mathcal{F}$

$$P(B) = \sum_i P(B \cap A_i).$$

Teorema 5: Desigualdade de Boole. Para n eventos arbitrários $\{A_1, \dots, A_n\}$, a desigualdade de Boole é representada por

$$P\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n P(A_i).$$

Exercício. Mostre que se $P(A_i) = 1$ então $P\left(\bigcap_{i=1}^n A_i\right) = 1$, para $i = 1, 2, 3, \dots$

- Como vimos anteriormente, existem muitas interpretações do conceito de probabilidade.
- Pode-se interpretar **probabilidade de um evento A como um limite das frequências relativas** de ocorrência do evento A em realizações independentes de um experimento.
- Em ambos os casos, probabilidade é baseada em informação e conhecimento. Em particular, **o conhecimento sobre um determinado evento que ocorreu pode influenciar na probabilidade** dos demais eventos.

Interpretação frequentista: Qual a probabilidade de um evento A , sabendo-se que um evento B ocorreu?

- Vamos realizar um experimento n vezes das quais o evento A ocorre N_A vezes.
- Observa-se que $r_A = \frac{N_A}{n}$ é a frequência relativa do evento A nestas n realizações do experimento.
- Assim, a probabilidade condicional do evento A dado que B ocorreu é igual ao limite das frequências relativas condicionais do evento A dado B , isto é,

$$P(A \text{ sabendo-se que } B \text{ ocorreu}) = \lim_{n \rightarrow \infty} \frac{N_{A \cap B}}{N_B} = \lim_{n \rightarrow \infty} \frac{r_{A \cap B}}{r_B} = \frac{P(A \cap B)}{P(B)}.$$

Probabilidade Condicional

Definição 6. Seja (Ω, \mathcal{F}, P) um espaço de probabilidade. Considere $A, B \in \mathcal{F}$ e $P(B) > 0$, a **probabilidade condicional de A dado B** é definida por

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

A probabilidade condicional também satisfaz as seguintes propriedades:

- $P(B|B) = 1$;
- $P(A|B) = P(A \cap B|B)$;
- Se $B \subseteq A$ então $P(A|B) = 1$;
- $P(A \cap B|C) = P(A|B \cap C) \cdot P(B|C)$.

Utilizando indução matemática, pode-se mostrar que

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1) \cdot P(A_2|A_1) \dots P(A_n|A_1 \cap \dots \cap A_{n-1}).$$